

המכון הטכנולוגי חולון (HIT) הפקולטה למדעי המחשב

מטלה 1: ניתוח נתונים חקרני (EDA) מנתונים להבנה

שם הסטודנט:	
מספר זהות:	
קורס:	מבוא למדעי הנתונים
מרצה:	ד"ר אורי איתי
מתרגלת:	חנית אוחיון חדד
בודק:	דרור מאירוביץ תאריך הגשה:
2.8.2026	
צורת ההגשה:	פרטנית

1 מטרת המטלה

ניתוח נתונים ראשוני הוא אחד הצעדים החשובים ביותר בניתוח נתונים אם לא החשוב ביותר. חשוב לעשות ניתוח מעמיק תוך כדי תקשור הממצאים בצורה ברורה עניינית ומלמדת. בתרגיל זה נתנסה בניתוח הראשון. מטרת מטלה זו היא לפתח הבנה עמוקה של מערך נתונים מעבר לויזואליזציה בסיסית. כאשר הניתוח יעשה מהורדת הנתונים ועד כתיבת דו"ח סיכום. כל סטודנט בוחר דאטה סט לפי רצונו. כאשר רצוי לבחור בנושא שקרוב לליבו של הסטודנט. יש להתייחס לנתונים כמערכת הכוללת:

- מבנה פנימי
- הנחות סמויות
- מגבלות והטיות

הגשה: באמצעות Git הסטודנטים יגישו לדואל homework@drorm.com
עבודה של סטודנט שלא יגיש כך או יגיש לתיבת ההגשה עבודתו לא תבדק ויקבל ציון 0 **דגשים להגשת העבודה**

- המחברת מהווה מסמך מקצועי לכל דבר. יש להקפיד על כתיבה ברורה, מסודרת ומדויקת, ללא שגיאות כתיב או דקדוק.

...

- כל ההסברים, ההערות בקוד (Comments), שמות הכותרות והתיעוד חייבים להיכתב באנגלית.
- יש להשתמש בשמות משמעותיים וברורים למשתנים, פונקציות ומחלקות. הימנעו משמות כלליים כגון `x`, `temp` או `data1`, אלא אם יש לכך הצדקה ברורה.

- יש להקפיד על עקרונות **Code Clean**: קוד קריא, מאורגן, מודולרי וקל לתחזוקה.
- מומלץ לחלק את הפתרון לפונקציות בעלות אחריות מוגדרת, להימנע מכפילויות בקוד ולשמור על מבנה לוגי ועקבי לאורך כל המחברת.
- הגשה איכותית אינה נמדדת רק בנכונות התוצאות, אלא גם באופן הצגתן, בארגון המחברת ובאיכות הקוד שנכתב. ``

2 בחירת מערך נתונים (15%)

2.1 דרישות

- מידע טבלאי
 - לפחות 1000 שורות
 - לפחות 10 עמודות
 - שילוב משתנים מספריים, משתני זמן, וקטגוריאליים
- בכל מקרה של ספק נא להתייעץ עם המתרגלת חנית חדד אוחיון.

2.2 תיאור מקור הנתונים

יש לפרט:

- מקור הנתונים
- מטרת האיסוף
- הגורם האוסף (אם ידוע)
- במידה ויש לך ידע על התחום נא לקשר אותו לטבלה

הערה: חוסר במידע זה מהווה תובנה.

3 מטא-אנליזה של הנתונים (15%)

3.1 ניתוח הקובץ

- גודל הקובץ

- פורמט
- תאריך יצירה (אם קיים)
- מטרת הנתונים

3.2 מבנה הנתונים

שלב זה מהווה הכרות ראשונית עם המידע. במידה וקיבלת תוצאות שונות ממה שציפית נא לציין. כמו כן כל מידע שעשוי להיות רלוונטי לקוד שיכתב על הנתונים הללו חייב להיות מצויין כאן.

- מספר שורות ועמודות
 - שמות העמודות, האם השמות הללו עושים הגיון? מה אפשר ללמוד מכך?
 - סוגי נתונים ואיזה טיפוס נתונים הם. האם יש תובנות על כך?
- דיון:** האם הנתונים נאספו לצורך מחקר או תפעול? אילו הטיית עשויות להופיע?

4 איכות ושלמות הנתונים (20%)

4.1 נתונים חסרים

- היקף החוסר
- דפוס (אקראי / מובנה)
- האם ניתן ללמוד או להסיק משהו מכך שחסרים נתונים?
- איך היית משלים את הנתונים החסרים

4.2 כפילויות

- כפילויות מלאות
- כפילויות חלקיות
- האם ניתן להסיק משהו מהכפילויות?
- האם כדאי להוריד את הכפילויות או להשתמש בשיטה אחרת

4.3 ערכים חשודים

- ערכים בלתי אפשריים
- values placeholder
- אפסים או מספרים שליליים לא סבירים
- האם אותם ערכים מספרים לנו משהו על המידע?

4.4 קרדינליות

- עמודות ללא שונות, האם יש עמודות עם ערך בודד?
- עמודות עם ריבוי ערכים ייחודיים

5 ניתוח חד-משתני (10%)

5.1 משתנים מספריים

- ממוצע, חציון, סטיית תקן, MAD מקסימום מינימום קוואנטייל IQR
- הטייה: האם הדטה מוטה לאחד הצדדים?
- התפלגות
- האם יש ערכים חריגים? נא להשתמש שלוש השיטות שלמדנו למציאת חריגים בחד מימד

5.2 משתנים קטגוריאליים

- שכיחויות. מה השכיח? איזה אחוז הדטה הוא תופס
- מה K המשתנים הכי נפוצים ואיזה אחוז מהדטה הם תופסים
- מה המספר הכי קטן של ערכים שצריך על מנת לתאר P אחוז מהדטה? מה הם אותם ערכים?
- קטגוריות נדירות? האם הם בעלות מידע או שאפשר להתעלם מהם? האם ניתן לאחד ערכים?

דיון: האם המדדים המרכזיים מייצגים היטב את הנתונים?

6 קורלציות וקשרים (20%)

6.1 מספרי-מספרי

- קורלציה על פי:
 - * פירסון
 - * ספירמן
 - * קנדל
- . נא להסביר את השוני
- מטריצת קורלציה
- גרפי פיזור
- איזה מסקנות אפשר להוציא על המתאם?

6.2 קטגוריאל-קטגוריאל

- טבלאות שכיחות
- V Cramér's (רשות)
- נא לעשות זאת עם בינינג. ולמצוא קשר בין המשתנים קטגורליים למספריים
- מה אפשר להסיק מכך למידע

6.3 גרפים

תמונה שווה אלף מילים. נא לסרטט גרפים שיתארו את הדטה כדאי לממש את הגרפים הבאים:

- *Scatterplot*
- *Histogram*
- *Barchart*
- *Boxplot*
- *Violin*
- *Piechart*
- *Pairplot*
- *Heatmaps*

במידה ויש גרפים נוספים שעשויים לעזור להבנת הנתונים נא להוסיפם.
הגרפים צריכים להיות מיידעים כמה שיותר להחיל כותרתת מקראת שמות לצירים. כמו כן לכתוב תובנות מהגרפים הללו

7 ניתוח אינדקס (5%)

- האם האינדקס ייחודי?
- האם מבוסס זמן?
- האם הניתוח למעלה משתנה בזמן?
- האם ממזין?

8 תובנות וסיפור הנתונים (15%)

נא לרשום סיכום מפורט על העבודה. הסיכום יכלול את הדגשים באים

- לפחות 3 תובנות מרכזיות
- לפחות הטיה או סיכון אחד
- נקודות כשל אפשריות לשימושים הנדסיים וסטיסטיים
- מה למדת בניתוח? האם יש נקודות שדעתך השתנתה על התחום?

9 בונוס (10%+)

- תלות בזמן. האם יש קשר למידע חיצוני שאנחנו יודעים על הזמן?
- Engineering Feature
- בדיקות השערות
- הצעות למחקר נוסף

10 קריטריוני הערכה

ניקוד	קטגוריה
15	בחירת הנתונים
15	מטא-אנליזה
20	איכות הנתונים
10	ניתוח חד-משתני
20	קורלציות
5	ניתוח אינדקס
15	תובנות
10+	בונוס

דגש למידה

הנתונים אינם "אמת" — הם תוצר של תהליך מדידה.

יש לשאול:

- מה נמדד?
- מה חסר?
- מה מוטעה?
- מה "ממוקד" באופן מלאכותי?